R-project-2020

Kilian DEBRAUX Anthony QUERE

17/11/2020

Figure 1: logo

Stack overflow est un site web de type forum permettant de poser ses questions à une communauté. Celle ci est principalement composée de développeurs. Nous avons obtennu nos données depuis **Les archives de stackexchange** (https://archive.org/details/stackexchange). Notre jeu de donnée a été réduit à 300 000 donnéespour être utilisable réparties sur 3 mois entre Août et Septembre 2020.

> Nous avons rencontré des problèmes avec notre jeu de donnée. Nous avons commencer à exploiter un jeu de donnée de la même source mais il s'est révélé incohérent et peu réaliste. Nous avons hélas mis beaucoup de temps à le remarquer et nous avons alors été confronté à un second problème. Le fichier que nous voulions était bien sur cette plateforme mais sous un autre nom et hélas u autre poids. Nous nous sommes donc retrouvés avec une archive de 15.6Go à télécharger avec de faibles connexions. Le premier téléchargement a échoué à la toute fin après de nombreuses heures mais nous avons rééssayé en passant cette fois ci par un *curl* et nous avons enfin eu les données dans un fichier de plus de 80 Go; nous l'avons bien sûr réduit. Nous avons eu très peu de temps entre ce moment et l'heure de rendu, nous esperons que vous pourrez en prendre considération pendant votre correction. Nous tenons à nous excuser pour la gêne occasionnée

Les technologies populaires

Cette fonction permet de récupérer des posts en fonction de tags mis sous forme de vecteur de regex

```
get_posts_by_tag <- function(dataset, tags) {
  regexes = paste("<", tags, ">", sep = "")
  posts <- c()
  for (r in regexes) {
    p <- subset(dataset, grepl(r, Tags))$Id
    posts <- union(posts, p)
  }
  return(posts)
}
```

```r
# get only questions posts
questions <- subset(posts, PostTypeId == "1")
```

Les tags le plus populaires

```r
sortedTags <- tags[order(tags$Count, decreasing = TRUE),]

TAGS_NUMBER = 10

mostPopularTags = head(sortedTags, n = TAGS_NUMBER)
lessPopularTags = tail(sortedTags, n = nrow(sortedTags) - TAGS_NUMBER)

otherValue = sum(lessPopularTags$Count)

pie(c(mostPopularTags$Count, otherValue), c(mostPopularTags$TagName, "Others"))
```

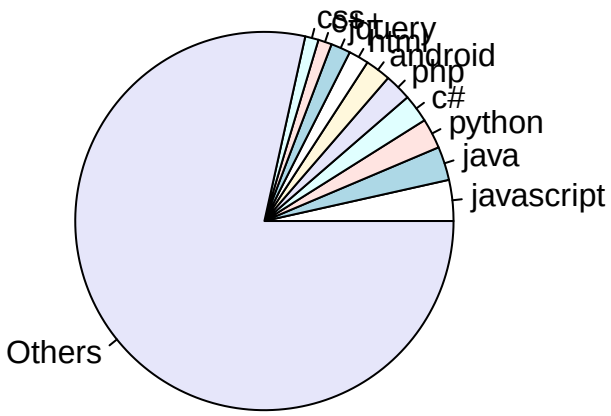

Nous avons pu récupérer le contenue de ce jeu de donnée car bien plus légé que le fichier principal. Nous pouvons constater par ce graphique que les tags les plus présents concèrenent essentielement les technologies du web (**Javascript**, **Php**, **HTML** et **CSS**; les autres technologies peuvent aussi servir en web comme le **Java** avec le framework *Spring* ou le **C#** avec *.net*). Nous avons choisi de n'en nommer que 10 pour des soucis de clarté. Ce diagramme nous permet de voir aisément les problématiques principales de la plateforme.

Les frameworks front-end

Les technologies évoluant contement en raison des besoins différents de chaque entreprise, plusieurs d'entre elles rendent disponibles des frameworks. Côté Front-End, on en retrouve 5 principaux : **Angular**, **Angular.js**

(il est important de les distinguer car ils n'ont pas du tout le même fonctionnement), **React.js**, **Vue.js** et **JQuery**. Nous voulons maintenant définir un "leader du marché" et montrer leurs différences de popularité.

```
angularRegex = c("angular", "angular[2-9]", "angular10")

angularjsRegex = c("angularjs", "angular1.6")

reactRegex = c("reactjs")

vueRegex = c("vue.js", "vuejs2")

jqueryRegex = c("jquery")

angularPosts <- get_posts_by_tag(questions, angularRegex)
angularjsPosts <- get_posts_by_tag(questions, angularjsRegex)
reactPosts <- get_posts_by_tag(questions, reactRegex)
vuePosts <- get_posts_by_tag(questions, vueRegex)
jqueryPosts <- get_posts_by_tag(questions, jqueryRegex)

i <- c(length(angularPosts), length(angularjsPosts), length(reactPosts), length(vuePosts), length(jquer
l <- c("Angular", "Angular.js", "React.js", "Vue.js", "JQuery")

pie(i, l)
```

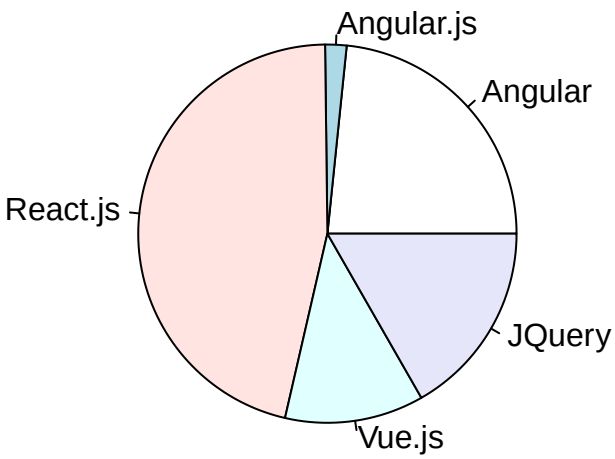

Nous pouvons constater que les frameworks **React** et **Angular** sont très appréciés par la communauté aujourd'hui, d'autant plus react qui a pour aventage d'être très efficace et maitrisable en peu de temps, Angular a plus de fonctionnalités de base (comme *RxJs*) mais est sur certains points plus complexe. On

retrouve ensuite le **Jquery** ce qui n'est pas très étonnant étant donné que c'est un framework simple qui est encore beaucoup utilisé dans de nombreux sites même s'il utilise aujourd'hui certaines fonctionnalités dépréciées. **Vue.js** est aussi très présent, c'est un framework simple et légé mais bien moins populaire que React et Angular. Nous avons choisi d'ajouter également **Angular.js** car il existe un débat Angular contre **Angular Js**. Angular.js, aussi appelé *Angular 1* est la version de base du projet Angular qui a connu un changement de langage en arrivant en version 2; **Angular** utilise du *Typescript* et **Angular.js** du *Javascript*, une partie de la communauté préfère rester sur du javascript.

Les distributions linux

```
ubuntuRegex = c("ubuntu", "ubuntu-[1-2][0-9]-[0-9][0-9]")

centosRegex = c("centos", "centos[0-9]")

redhatRegex = c("redhat")

debianRegex = c("debian")

fedoraRegex = c("fedora", "fedora-[0-9]", "fedora-[0-9][0-9]")


ubuntuPosts <- get_posts_by_tag(questions, ubuntuRegex)
centosPosts <- get_posts_by_tag(questions, centosRegex)
redhatPosts <- get_posts_by_tag(questions, redhatRegex)
debianPosts <- get_posts_by_tag(questions, debianRegex)
fedoraPosts <- get_posts_by_tag(questions, fedoraRegex)

i <- c(length(ubuntuPosts), length(centosPosts), length(redhatPosts), length(debianPosts), length(fedora
l <- c("Ubuntu", "Centos", "RedHat", "Debian", "Fedora")

pie(i, l)
```

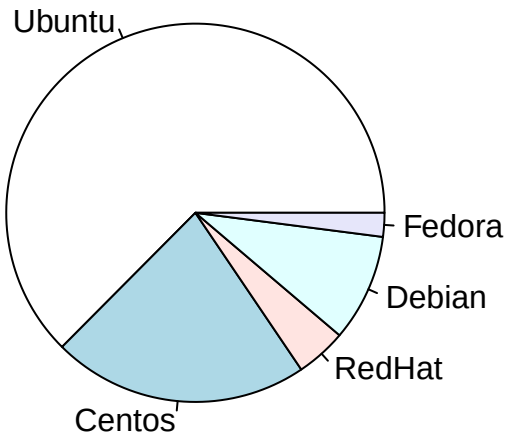

Malgré notre choix de proposer 2 distributions basées sur Debian et 3 sur Centos, nous constatons une très grande préférence pour les distributions basées sur Debian à savoir **Debian** et **Ubuntu**. C'est le résultat que nous attendions car ces distributions linux sont très utilisées par la communauté pour leur utilisation personnelle. Les distributions issues de **Centos** (sauf **Fedora**) sont bien plus utilisées en leur version server, donc avec uniquement la *command line*, dans un contexte d'entreprise, c'est pourquoi on le retrouve en moins grande majorité.

Les langages de programmation

```
cRegex = c("c")

csRegex = c("c#")

cppRegex = c("c\\+\\+")

pythonRegex = c("python")

javaRegex = c("java")

dartRegex = c("dart")

jsRegex = c("javascript")

tsRegex = c("typescript")

rubyRegex = c("ruby")
```

```r
phpRegex = c("php")


cPosts <- get_posts_by_tag(questions, cRegex)
csPosts <- get_posts_by_tag(questions, csRegex)
cppPosts <- get_posts_by_tag(questions, cppRegex)
pythonPosts <- get_posts_by_tag(questions, pythonRegex)
javaPosts <- get_posts_by_tag(questions, javaRegex)
dartPosts <- get_posts_by_tag(questions, dartRegex)
jsPosts <- get_posts_by_tag(questions, jsRegex)
tsPosts <- get_posts_by_tag(questions, tsRegex)
rubyPosts <- get_posts_by_tag(questions, rubyRegex)
phpPosts <- get_posts_by_tag(questions, phpRegex)

i <- c(length(cPosts), length(csPosts), length(cppPosts), length(pythonPosts), length(javaPosts), lengt
l <- c("C", "C#", "C++", "Python", "Java", "Dart", "Javascript", "Typescript", "Ruby", "Php")

pie(i, l)
```

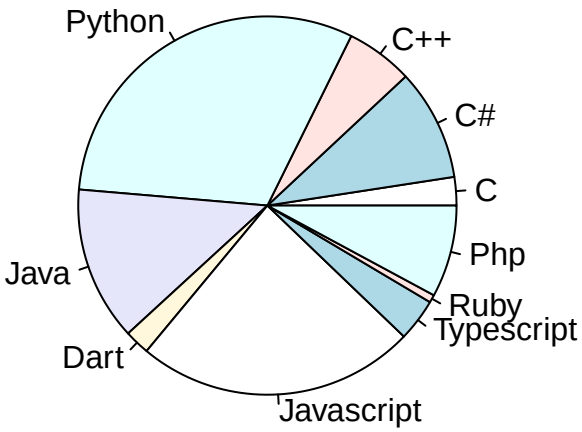

On les langages les plus présents sur ce diagramme sont le **Python** et le **Javascript**. Ce sont des langages très polivalents, le **Javascript** est un obligtoire du web Front-End et peut être utilisé également comme Back-End. De la même manière le **Python** peu être utilisé aussi bien pour du web Back-End, de l'automatisation, de l'inteligence artificielle... Le java a pour aventage qu'un même code peut être utilisable sur Windows, Linux et Mac, de plus c'est un langage natif pour Android. Le **C#** est utilisé en web avec .net mais aussi dans le monde du jeu vidéo. Le php est encore massivement utilisé en web Back-End même si la tendance est largement en baisse depuis de nombreuses années au profit du **Java* avec *Spring* , du** Python** avec

Django, du **Javascript** avec *Node*...

Les IDE (Environnement de développement)

```
vscRegex = c("visual\\-studio\\-code")

vsRegex = c("visual\\-studio")

eclipseRegex = c("eclipse")

atomRegex = c("atom\\-editor")

intellijRegex = c("intellij\\-idea")

sublRegex = c("sublimetext[1-3]?")


vscPosts <- get_posts_by_tag(questions, vscRegex)
vsPosts <- get_posts_by_tag(questions, vsRegex)
eclipsePosts <- get_posts_by_tag(questions, eclipseRegex)
atomPosts <- get_posts_by_tag(questions, atomRegex)
intellijPosts <- get_posts_by_tag(questions, intellijRegex)
sublPosts <- get_posts_by_tag(questions, sublRegex)

i <- c(length(vscPosts), length(vsPosts), length(eclipsePosts), length(atomPosts), length(intellijPosts)
l <- c("Visual Studio Code", "Visual Studio", "Eclipse", "Atom", "Intellij", "Sublim Text")

pie(i, l)
```

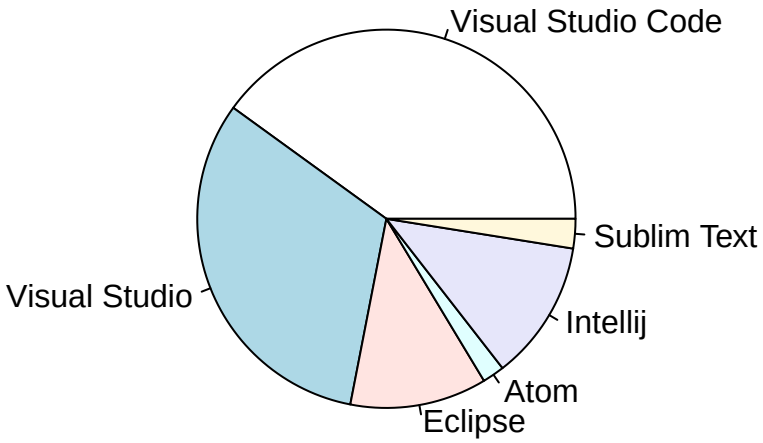

On remarque directement la dominance des ide de microsoft **Visual Studio** et **Visual Studio Code**. Le premier est essentiellement utilisé pourdévelopper en C, C# et C++ et le second est de très loin l'ide le plus populaire. Il peut être utilisé pour pratiquement tous les langages et frameworks et est très adaptable avec de nombreux plugins pour utiliser Git, Docker, R, ... In tellij est aussi très populaire, dans a version IDEA il peut même être plus puisant que Visual Studio Code sous certains aspets notement dans le dévelppement d'appliations regroupant plusieurs technologies comme une API en Spring, un client en React et une base de donnée PostgreSQL, cependant il est payant et donc moins utilisé. Eclipse est très utilisé pour le java mais l'entreprise a de moins en moins de succès et cet ide est de moins en mois utilisé. Atom et Visual Studio Code ressemblent à Visual Studio Code mais permettent moins de choses.